Santiago centro: ciudad construida y transporte público

Informe Tarea 1 · Procesamiento Masivo de Datos (ELE051-B / EIN102B) · USM 2026-2 · Paralelo 701 · Profesor Diego Ramírez

Integrantes: Diego Peña, Benjamín Tello · Repositorio: github.com/diego-alonso23/Tarea-PostGIS

Pregunta que ordena el trabajo: ¿cómo se relaciona la ciudad construida (OpenStreetMap) con la red de transporte público (GTFS)? Zona de estudio: caja lon -70,75 … -70,52, lat -33,52 … -33,36 (30 comunas, total o parcialmente). Todo está en PostGIS, en SRID 5361. Cada conclusión indica su fuente y fecha: los paraderos de OSM son los que alguien dibujó; el GTFS es lo que el operador declara.

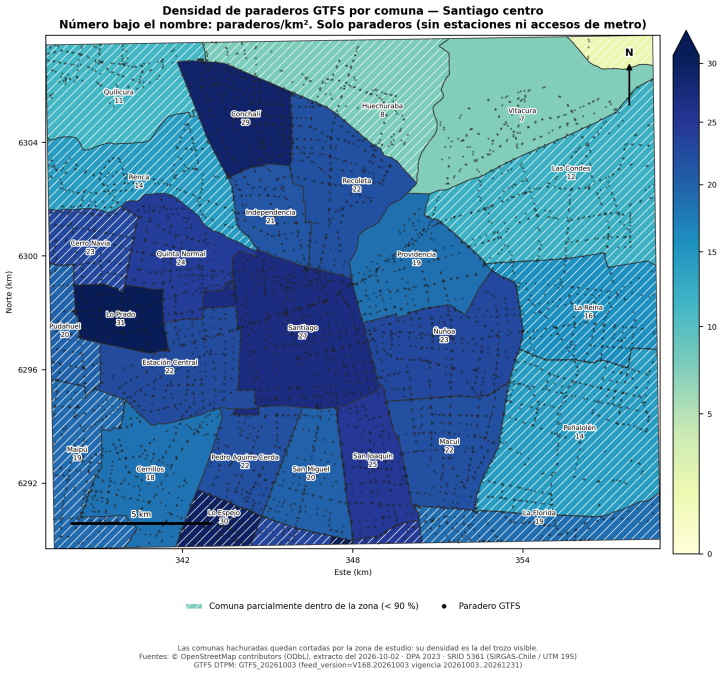
1 Paraderos por comuna y densidad

Join punto-en-polígono: se recorta cada comuna a la caja y se cuentan los paraderos GTFS (sin estaciones ni accesos de metro). Se asignan 6 810 paraderos a 30 comunas; la densidad usa el área de la comuna dentro de la caja.

Comuna	Paraderos	Área en la caja (km^2)	Paraderos/km^2
San Ramón	6	0,17	35,85
Lo Prado	201	6,54	30,72
Lo Espejo	120	4,06	29,59
Conchalí	317	10,94	28,98
Santiago	624	23,18	26,92
…			
Huechuraba	163	20,96	7,78
Vitacura	194	26,33	7,37
Lo Barnechea	5	2,80	1,79

INTERPRETACIÓN

Las comunas del centro y poniente (Lo Prado, Lo Espejo, Conchalí, Santiago) concentran más paraderos por km^2; las del oriente y norte (Vitacura, Huechuraba, Lo Barnechea) son las menos densas. San Ramón y Lo Barnechea tienen muy poca área dentro de la caja, así que su densidad corresponde a un trozo pequeño y no representa a la comuna (en el mapa están hachuradas las comunas cortadas por la caja).



Mapa 1. Densidad de paraderos GTFS por comuna (GTFS_20261003, DPA 2023; datos al 2026-10-03).

2 Cobertura: edificios a más de 500 m de un paradero

Anti-join NOT EXISTS + ST_DWithin(geom_pt, paradero, 500) sobre el punto interior de cada edificio, una vez con paraderos GTFS y otra con paraderos OSM. En las 30 comunas hay 118 973 edificios: 1 347 (1,13 %) están a más de 500 m de un paradero GTFS y 1 156 (0,97 %) a más de 500 m de un paradero OSM.

Comuna	Edificios	% sin GTFS	% sin OSM
Lo Barnechea	76	61,84	61,84
Huechuraba	1 268	10,73	10,41
Quilicura	2 291	7,46	7,55
La Florida	953	4,51	4,51
Vitacura	4 014	3,96	3,94
Providencia	12 133	0,73	0,15
La Reina	11 878	1,76	1,25
Recoleta	3 086	1,88	0,97
Otras 15 comunas (Santiago, Ñuñoa, Macul, San Joaquín…)		0,00 a 0,14	0,00 a 0,14

INTERPRETACIÓN

Casi toda la ciudad construida está a menos de 500 m de un paradero con cualquiera de las dos fuentes, y la conclusión no cambia según la fuente: las comunas con más edificios sin cobertura son las mismas (Lo Barnechea, Huechuraba, Quilicura). La fuente sí importa en Providencia, La Reina y Recoleta, donde OSM deja menos edificios sin cobertura que el GTFS, lo que sugiere que OSM tiene paraderos que el GTFS no declara cerca de esos edificios. Lo Barnechea (76 edificios en la caja) está en el borde y no es concluyente.

3 Dos fuentes, un objeto

Anti-join en los dos sentidos con un umbral de 50 m: paraderos GTFS sin ningún bus stop OSM cerca, y bus stops OSM sin ningún paradero GTFS cerca.

Paraderos GTFS	GTFS sin bus stop OSM (< 50 m)	Bus stops OSM	OSM sin paradero GTFS (< 50 m)
6 812	448 (6,6 %)	6 572	361 (5,5 %)

INTERPRETACIÓN

Más de 9 de cada 10 objetos tienen su par en la otra fuente, así que ambas describen en gran medida la misma red, pero ninguna es completa: 448 paraderos que el operador declara no están dibujados en OSM, y 361 bus stops de OSM no tienen paradero GTFS cerca (pueden estar mal ubicados, ser paraderos que el operador no declara o haber dejado de existir). El umbral de 50 m influye: un paradero desplazado más que eso aparece como faltante en ambos sentidos.

Plan de ejecución comentado (índice usado, de qué lado y qué pasa sin él): ver README del repositorio, sección 5, y resultados/planes_y_estado.txt.

4 Kilómetros de recorrido por comuna

Cada trazado se recorta en el límite comunal con ST_Intersection contra comunas_sub (comunas subdivididas con ST_Subdivide, 256 vértices) y se suma ST_Length por comuna.

Comuna	Shapes	Rutas distintas	km de trazado
Santiago	323	156	1 339,99
Maipú	139	65	1 283,86
La Florida	156	67	840,46
Pudahuel	149	69	798,48
Las Condes	139	74	767,66
…			
Independencia	60	42	204,23
La Granja	68	36	185,40
San Ramón	65	30	155,24

INTERPRETACIÓN

Santiago es la comuna con más kilómetros de trazado y más rutas distintas (156). Maipú, La Florida y Pudahuel aparecen altas porque los shapes se recortan al límite comunal pero no a la caja: incluyen trazados fuera de la zona de estudio (Maipú tiene solo unos 11 km^2 dentro de la caja). Además, ida, vuelta y variantes suman por separado, así que los km miden longitud de trazados y no longitud de red. El efecto de ST_Subdivide en el tiempo se mide en el repositorio (sql/9_planes.sql, sección 4).

5 Vecino más cercano

Ruta elegida: route_short_name = '210'. Para cada paradero de la ruta, la farmacia, hospital, clínica o consultorio más cercano (CROSS JOIN LATERAL + <-> + LIMIT 1). Los 15 paraderos con menor distancia:

Paradero	Servicio más cercano	Tipo	Distancia (m)
PA168 · (M) Santa Lucía	Farmacias del Dr. Simi	pharmacy	5,3
PA215 · (M) La Moneda	Cruz Verde	pharmacy	9,9
PA187 · (M) República	Farmacia Ochoa	pharmacy	17,2
PA184 · (M) La Moneda	SalcoBrand	pharmacy	19,7
PI440 · San Borja	Naturland	pharmacy	25,8
…			
PE1499 · Av. Vicuña Mackenna / El Manzano	Fonasa	clinic	42,7

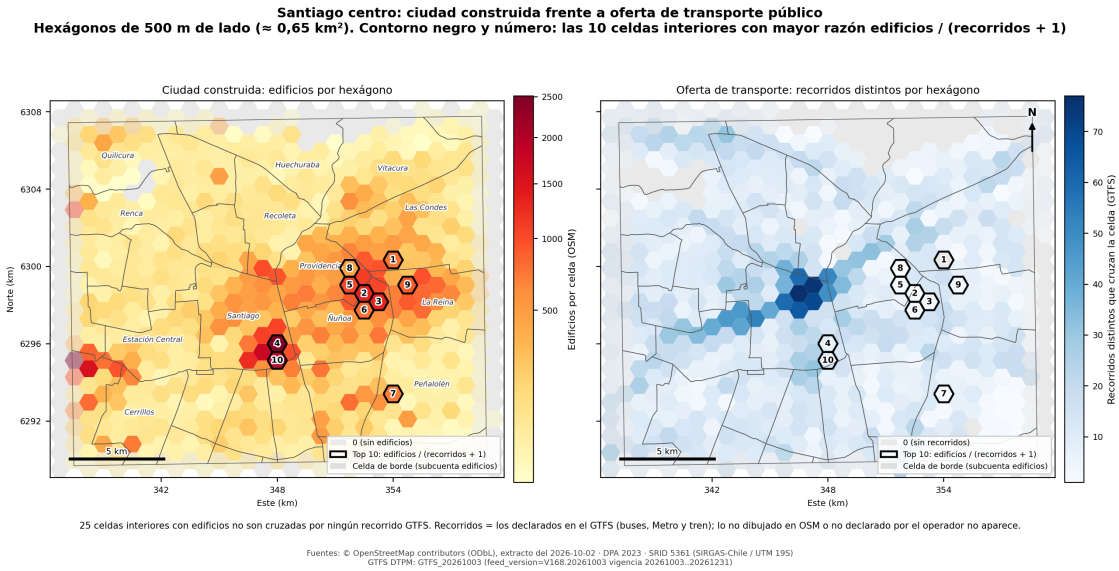
INTERPRETACIÓN

Los 15 paraderos de la ruta 210 más cercanos a un servicio de salud tienen uno a menos de 45 m, casi todos una farmacia. La tabla muestra solo esos 15 (LIMIT 15 sobre el resultado ordenado), por lo que no resume la distancia típica de toda la ruta.

Planes de ejecución comentados: ver README del repositorio, sección 5.

6 Grilla hexagonal de 500 m (mapa principal)

ST_HexagonGrid de 500 m de lado (aprox. 0,65 km^2 por celda) sobre la caja, materializada como vista (mv_grilla): 682 celdas, 525 completamente dentro de la caja. Edificios por celda = puntos interiores de edificios OSM; recorridos distintos = route_short_name distintos cuyos shapes GTFS cruzan la celda.



Mapa 2. Edificios (OSM) y recorridos distintos (GTFS) por hexágono. Contorno y número: top 10 (OSM 2026-10-02, GTFS_20261003, DPA 2023; datos al 2026-10-03).

Criterio del top 10: mayor razón *edificios / (recorridos + 1)*, solo en celdas interiores (los edificios solo existen dentro de la caja, así que las celdas de borde subcuentan edificios).

#	Celda	Edificios	Recorridos	#	Celda	Edificios	Recorridos
1	519	755	0	6	472	765	2
2	473	1 344	3	7	511	702	2
3	495	1 321	3	8	453	456	1
4	338	2 450	7	9	540	894	3
5	452	1 028	3	10	337	1 870	10

INTERPRETACIÓN

Hay 25 celdas interiores con edificios que ningún recorrido GTFS cruza. Las 10 celdas del ranking se concentran en el sector oriente (Providencia, Ñuñoa, La Reina y una en Peñalolén) y en dos celdas del centro-sur de Santiago: zonas muy construidas con pocos recorridos que las crucen. El ranking depende de nuestro criterio: con otro (por ejemplo, solo celdas con 0 recorridos) el top 10 cambia. Los recorridos son los declarados en el GTFS (buses, Metro y tren); lo no dibujado en OSM o no declarado por el operador no aparece.

7 La propia: ¿qué hay cerca de los paraderos con más viajes?

Pregunta: ¿qué amenidades OSM rodean a los paraderos con más viajes declarados en el GTFS? Cruza viajes_por_paradero (desde stop_times.txt, 1 098 529 filas cargadas con \copy) con las amenidades de OSM a 100 m de cada paradero: cuántas y cuántos tipos distintos.

Paradero	Viajes	Amenidades a 100 m	Tipos distintos
Pedro de Valdivia (L1)	1 353	34	10
Los Leones (L1)	1 353	33	12
Manuel Montt (L1)	1 353	33	11
El Golf (L1)	1 353	25	15
Tobalaba (L1)	1 353	25	11
Salvador (L1)	1 353	7	7
Baquedano (L1)	1 353	7	6

INTERPRETACIÓN

Los 15 paraderos con más viajes son todos estaciones de la Línea 1 del Metro, empatadas en 1 353 viajes, por lo que el orden entre ellas depende del ORDER BY y no del dato. Dentro de la L1, las estaciones del sector oriente (Pedro de Valdivia, Los Leones, Manuel Montt, El Golf) tienen más amenidades OSM a 100 m que Salvador o Baquedano. El ranking no incluye paraderos de buses.

Qué dicen las dos fuentes juntas

- **Cobertura alta en ambas fuentes:** el 98,9 % de los edificios está a menos de 500 m de un paradero GTFS y el 99,0 % a menos de 500 m de uno OSM (P2). La brecha está en el borde de la zona (Lo Barnechea, Huechuraba, Quilicura).
- **Las fuentes no coinciden del todo:** alrededor del 6 % de los objetos de cada fuente no tiene par a 50 m en la otra (P3). Ni OSM ni el GTFS son el «censo» de paraderos.
- **Oferta desigual:** las comunas del centro y poniente tienen más paraderos por km^2 (P1), y 25 celdas interiores con edificios no son cruzadas por ningún recorrido GTFS (P6).
- **Cuidado con los números:** los km por comuna (P4) incluyen trazados fuera de la caja y suman ida, vuelta y variantes; el top 10 de la grilla (P6) depende de un criterio elegido por nosotros.

Limitaciones de este trabajo

- P4 recorta los trazados al límite comunal, no a la caja; P5 muestra solo los 15 paraderos con menor distancia; P7 queda dominada por estaciones del Metro empatadas en viajes.
- Los datos OSM y GTFS son de una fecha puntual (2026-10-02 y 2026-10-03); el GTFS cambia y OSM se edita todos los días.

Decisiones del pipeline

Todo se reproduce con `docker compose up -d` y `./cargar.sh` (ver README del repositorio).

- **SRID 5361** (SIRGAS-Chile / UTM 19S) para todo, porque permite medir en metros (`ST_DWithin`, áreas, largos). OSM y GTFS vienen en 4326 y se transforman al cargar; `comunas_cl` ya viene en 5361.
- **Carga de OSM:** `ogr2ogr -spat` directo sobre el PBF de Chile (≈ 15 s, ≈ 200 MB de RAM). `osmium extract` pedía más de 3 GB y moría por falta de memoria. Los objetos que cruzan el borde de la caja quedan completos.
- **Reparaciones con `ST_MakeValid`:** de 146 675 multipolígonos OSM, 291 eran inválidos; 181 eran edificios. Tras repararlos se descartaron 155 edificios por quedar vacíos o sin área, y 26 edificios reparados están en la tabla final. GDAL emitió además 86 avisos de anillos degenerados. Las comunas no necesitaron reparación (0 inválidas).
- **Punto interior vs polígono:** los edificios guardan ambos. `geom` (MultiPolygon) sirve para áreas e intersecciones; `geom_pt = ST_PointOnSurface(geom)`, a diferencia del centroide, siempre cae dentro del edificio y hace baratos los joins punto-en-polígono y `ST_DWithin`. P2 y P6 usan `geom_pt`, así cada edificio cuenta una sola vez.
- **GTFS:** los CSV se cargan con `COPY` (no INSERT fila por fila): 456 573 puntos de `shapes.txt` y 1 098 529 filas de `stop_times.txt`. `paraderos_gtfs` se construye con `ST_MakePoint` a 4326, se transforma a 5361 y se recorta a la caja en la base (se descartan 11 293 de 18 455 paradas). Se filtran paraderos (`location_type` vacío o 0) para no contar estaciones y accesos de metro dos veces.
- **Recorridos:** una LineString por `shape_id` con `ST_MakeLine(punto ORDER BY shape_pt_sequence)`; la ruta se asocia vía trips → routes. Se decidió una fila por shape: ida, vuelta y variantes quedan separadas (con `route_short_name` y `direction_id` para agruparlas). De 981 shapes, 122 no tienen viajes y se excluyen; ninguno es usado por más de una ruta; 708 cruzan la caja y se guardan completos (0 de largo cero).
- **DPA y `ST_Subdivide`:** `comunas_sub` subdivide con 256 vértices solo las comunas que tocan la caja (86 piezas) y se usa en los joins pesados (P2, P4). En P1 se mide el área de la comuna recortada a la caja.
- **Índices:** GIST sobre cada geometría (edificios tiene dos: `geom` y `geom_pt`), btree en `route_short_name`, `amenity` y `highway`, y ANALYZE al final de la carga. El uso real de cada índice (`pg_stat_user_indexes`) y cuáles resultaron inútiles se reporta en el README del repositorio, sección 7.
- **Grilla:** hexágonos de 500 m de lado; ranking sobre celdas interiores con la razón edificios / (recorridos + 1). El primer criterio (menos recorridos, luego más edificios) dejaba solo celdas con 0 recorridos, incluidas celdas de borde donde los edificios están subcontados, y se descartó.
- **Honestidad con el dato:** cada mapa y tabla lleva la fuente y la fecha. Los paraderos OSM son los que alguien dibujó; el GTFS es lo que el operador declara.